FARMTECH
VISIONGUARD RURAL

Relatório técnico de visão computacional | FIAP Fase 6

Aluno: Pedro Gomes12 **RM:** 571446 **Grupo:** 60

Curso: Tecnologia em Inteligência Artificial (On-Line)

Escopo: detecção de pessoa e carro, comparação YOLO e CNN, demonstração de monitoramento rural.

Base documental: notebook executado e arquivos de resultados incluídos no ZIP de entrega.

Síntese executiva. Quatro abordagens foram avaliadas sobre oito imagens de teste: YOLOv5 customizada com 30 e 60 épocas, YOLOv5 pública COCO e CNN binária treinada do zero. O maior mAP@50 observado foi 89,58% na YOLO 60. A CNN alcançou 50% de acurácia. Estas evidências indicam potencial demonstrativo, não prontidão de operação real.

Ressalva acadêmica essencial: o arquivo de status registra DEMO_OPENIMAGES_OFFICIAL. Portanto, a rotulagem manual Make Sense requerida pela FIAP não está comprovada.

1 | Problema de negócio e aplicação rural

Em fazendas, pontos de acesso como porteiras e vias internas concentram circulação de pessoas e veículos. Uma câmera associada a um detector pode localizar visualmente objetos e registrar ocorrências para conferência humana. O objetivo deste projeto é apresentar essa tecnologia de maneira verificável, sem equiparar detecção a reconhecimento de identidade ou comportamento ilícito.

A aplicação foi concebida como sistema local em Windows, com painel no navegador, ingestão de fotografias, vídeos e câmera compatível. Os resultados acadêmicos são independentes do funcionamento dessa interface: a avaliação de notas exige sobretudo o notebook executado, discussão crítica e documentação.

2 | O que são YOLO, CNN, epochs e bounding boxes?

Visão computacional: área da IA que extrai informações de pixels. **YOLO:** detector que estima, numa única passagem, classes, posições e níveis de confiança. **Bounding box:** retângulo que delimita o objeto detectado. **Confiabilidade/confiança:** score atribuído à previsão, não uma probabilidade certificada de presença em qualquer situação.

CNN: rede neural convolucional que aprende padrões espaciais. No projeto, foi usada para classificação binária de uma imagem inteira, diferentemente da YOLO, que localiza objetos. **Época:** passagem de treinamento sobre o dataset; dobrar épocas não garante generalização e pode aumentar overfitting.

3 | Metodologia e divisão de dados

Classe	Treino	Validação	Teste	Total
Pessoa	32	4	4	40
Carro	32	4	4	40
Total	64	8	8	80

Amostra do Open Images, com rótulos de referência. A divisão mantém separação funcional entre treino (ajuste de parâmetros), validação (seleção/monitoramento) e teste (medição final). A documentação não comprova revisão manual Make Sense das 64 imagens de treino; o status aponta uso de rótulos oficiais para a execução disponibilizada.

4 | Hipóteses e configuração de experimentos

H1: treinar YOLOv5s durante 60 épocas pode aumentar o AP comparado a 30 épocas. H2: a YOLOv5 COCO sem customização pode oferecer um baseline competitivo. H3: uma CNN pequena treinada do zero pode ter desempenho limitado em 64 imagens. Essas hipóteses só podem ser discutidas para esta amostra, e não como regra universal.

5 | Métricas: o que cada uma realmente mede

Precision: proporção de detecções positivas que são verdadeiras entre as detecções aceitas no limiar. **Recall:** proporção de objetos anotados que foram recuperados. **F1:** média harmônica de precision e recall. **AP@50:** área sob curva precisão versus recall de uma classe com exigência de sobreposição IoU maior ou igual a 0,50. **mAP@50:** média dos APs por classe. **Accuracy:** proporção de imagens classificadas corretamente, apropriada à CNN mas não comparável diretamente com mAP.

Alerta metodológico: a precision extremamente baixa dos detectores foi obtida com confiança mínima muito reduzida na avaliação. Isso admite muitas caixas de baixa confiança. O mAP é construído a partir da curva, enquanto precision e recall reportados descrevem o limiar escolhido; por isso as grandezas podem parecer contraditórias.

6 | Resultados quantitativos observados

Modelo	mAP50	Precision	Recall	Inferência
YOLOv5 30	76,25%	0,31%	100%	86,48 ms
YOLOv5 60	89,58%	2,25%	100%	26,86 ms
YOLOv5 padrão	87,50%	5,23%	100%	23,96 ms
CNN zero	não aplicável	0%	0%	20,43 ms

Tempos de treino registrados: YOLO 30 = 89,00 s; YOLO 60 = 104,46 s; CNN = 9,98 s. CNN: accuracy 50%, macro-precision 25%, macro-recall 50% e macro-F1 33,33%. As diferenças de tempo são experimentais e não representam benchmark industrial.

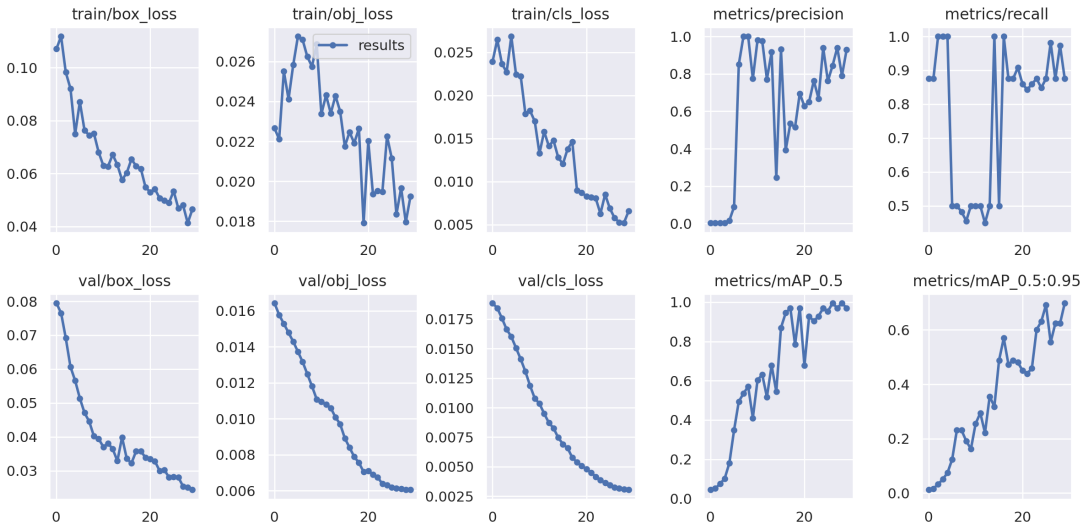
7 | Comparação das classes e análise crítica

Detector	AP50 pessoa	AP50 carro
YOLO 30	52,50%	100%
YOLO 60	79,17%	100%
YOLO padrão	75,00%	100%

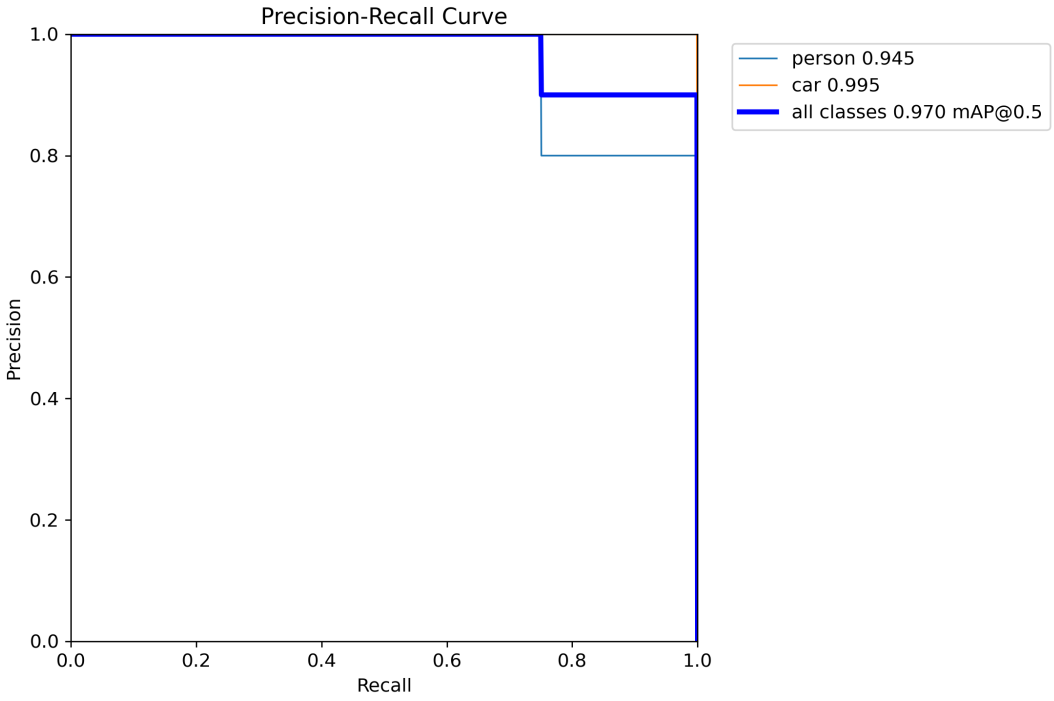
Na amostra, a classe carro atingiu AP50 igual a 100% em todos os detectores, mas isso se refere a pouquíssimos exemplos. A classe pessoa mostrou maior variabilidade. A melhoria de 76,25% para 89,58% no mAP50 corresponde a +13,33 pontos percentuais, sem provar robustez fora da amostra.

8 | Evidências visuais: curvas do treinamento de 30 épocas

Evolução das métricas e perdas ao longo das 30 épocas

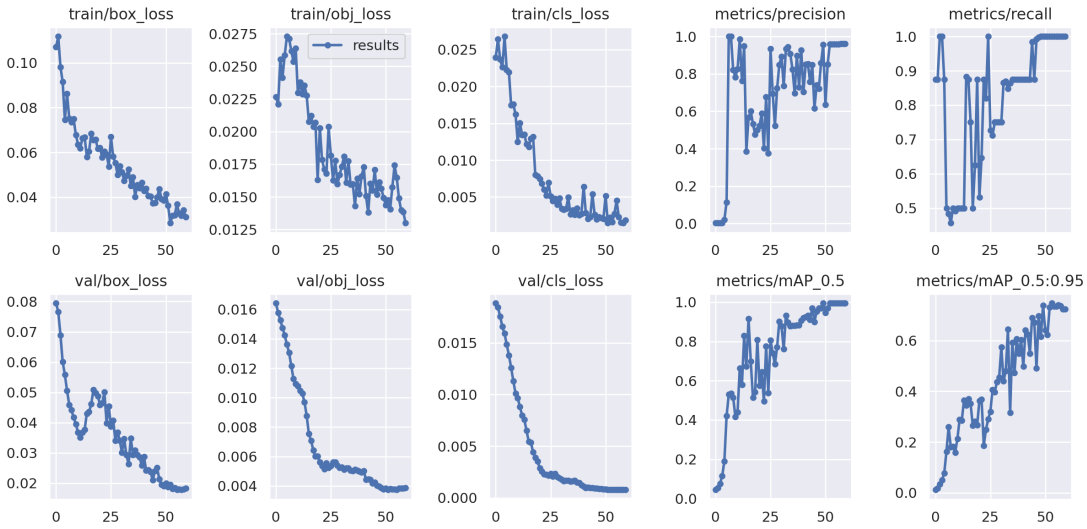


Curva de precisão versus recall, detector de 30 épocas

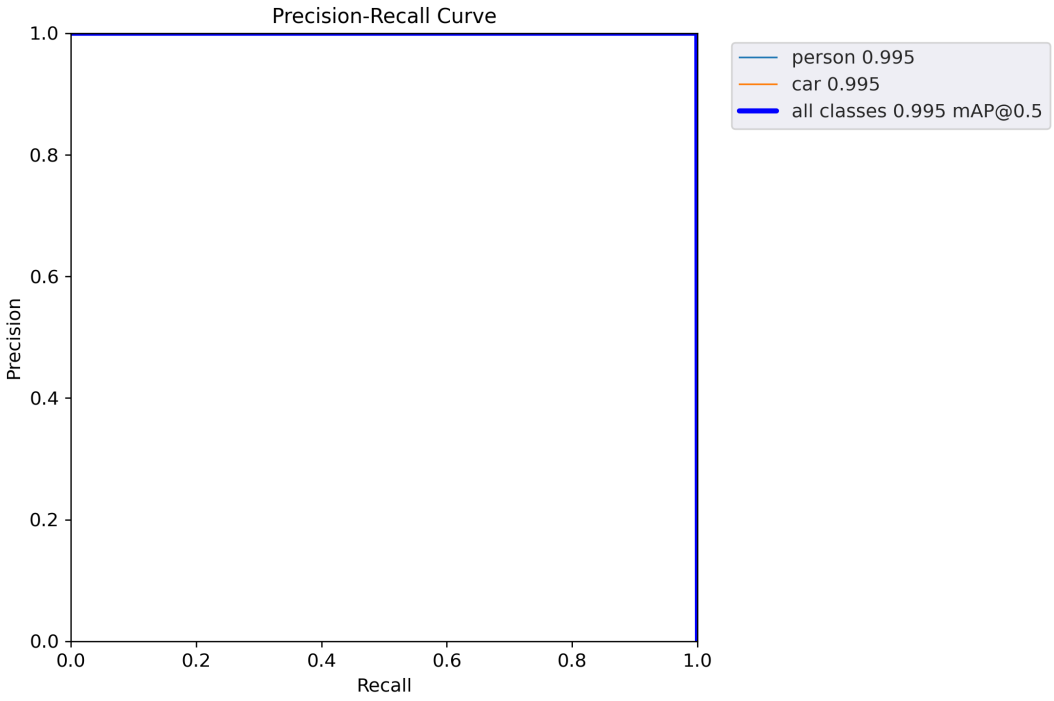


9 | Evidências visuais: curvas do treinamento de 60 épocas

Evolução de métricas e perdas ao longo das 60 épocas

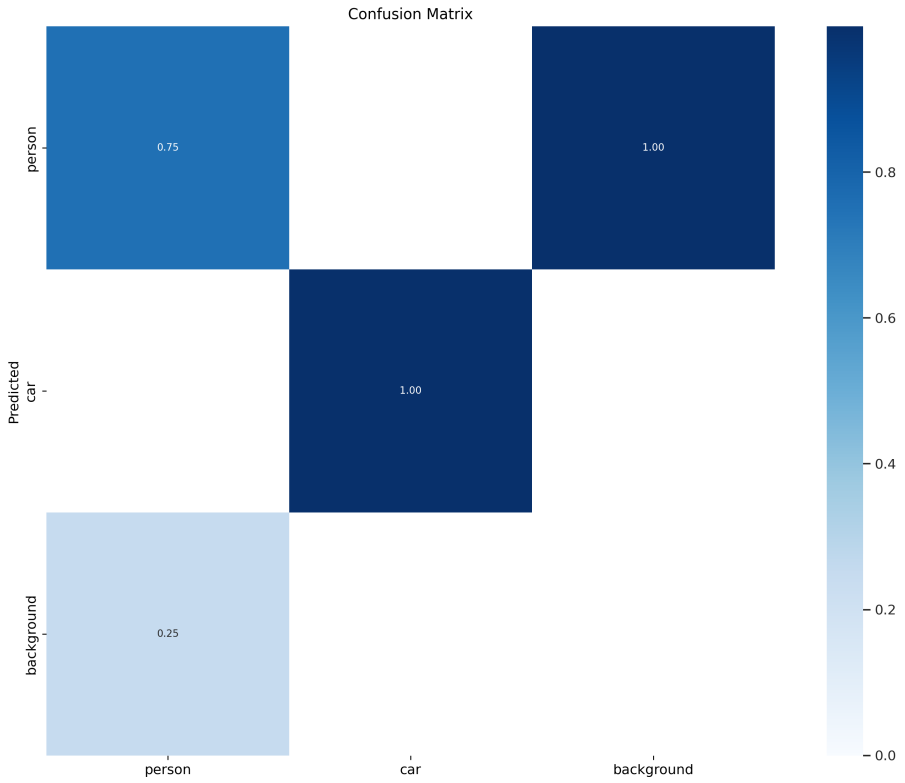


Curva de precisão versus recall, detector de 60 épocas

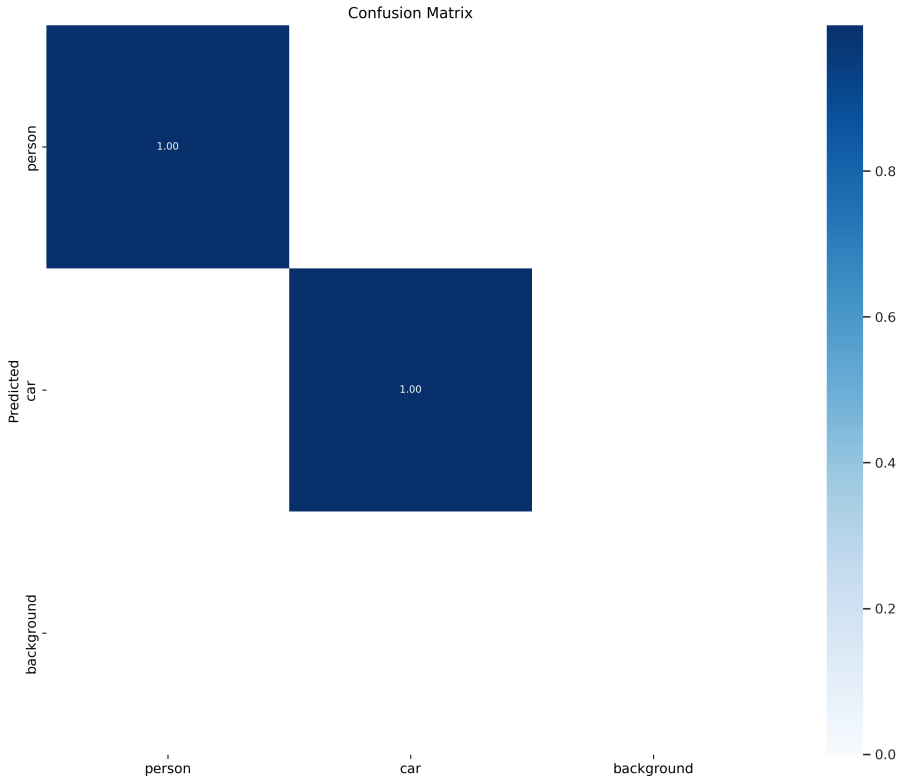


10 | Matrizes de confusão

YOLOv5 customizada com 30 épocas



YOLOv5 customizada com 60 épocas



11 | Arquitetura do protótipo de fazenda

O módulo operacional utiliza entrada de imagem, vídeo ou câmera RTSP/webcam, camada de inferência para detecção, filtros de zona e confiança, armazenamento local de eventos em SQLite e painel visual. A versão acadêmica produz pesos e métricas; o aplicativo pode utilizar pesos públicos para demonstração ou o arquivo best.pt quando disponibilizado.

Instalação local: com Python 3.11 recomendado, execute INICIAR_FAZENDA_WINDOWS.bat e acesse o endereço local do Streamlit. A primeira instalação depende de rede e do download de bibliotecas e pesos. O relatório não afirma teste contínuo com câmera real.

12 | Diferença entre modelo experimental e produto operacional

Um modelo válido em notebook não basta para uma aplicação de segurança. Um projeto pronto para uso comercial exigiria imagens reais da porteira, avaliação de dia/noite, falso alarme por hora, latência sob carga, tolerância a falhas, monitoramento de câmera offline, proteção de acesso, política de privacidade e acompanhamento humano dos eventos.

13 | Limitações verificadas

1. O conjunto de teste possui oito imagens. 2. As anotações de treino registradas são oficiais e não há comprovação de Make Sense manual. 3. Valores de precision em limiar baixo são insuficientes para estimar taxa operacional de falsos alarmes. 4. A CNN não excedeu o acaso na accuracy da amostra balanceada. 5. Resultados em fotografias genéricas não garantem desempenho com veículos agrícolas, ângulos fixos ou baixa luminosidade.

14 | Reprodutibilidade técnica

Seed: 42; Python: 3.13.15 (main, Aug 6 2026, 11:06:22) [GCC 13.3.0]; PyTorch: 2.11.0+cu130; TensorFlow: 2.21.0; commit YOLOv5: 915bbf294bb74c859f0b41f1c23bc395014ea679.

Os resultados numéricos têm como fonte os JSONs em results/; as curvas são os PNGs dos experimentos. As 24 células de código do notebook incluído possuem execução registrada e nenhum output com erro no arquivo inspecionado.

15 | Conclusões por hipótese

H1: para a amostra testada, a YOLO 60 apresentou mAP@50 maior que a YOLO 30. **H2:** a YOLO pública também demonstrou mAP alto e inferência média menor, sendo baseline relevante. **H3:** a CNN pequena treinada do zero não demonstrou capacidade de generalização, pois accuracy ficou em 50%. Os resultados sustentam uma demonstração acadêmica com discussão crítica, não a superioridade universal de uma solução.

16 | Checklist da FIAP: evidências e pendências

Requisito	Evidência identificada
80 imagens, 64/8/8	dataset ZIP e descrição; conferir conteúdo antes da correção
YOLO 30 e 60 épocas	métricas JSON, curvas e notebook executado
YOLO padrão / CNN	JSONs e notebook com saídas
Make Sense manual	PENDENTE: estado DEMO_OPENIMAGES_OFFICIAL
GitHub / Colab	URLs informadas; testar visualização pública
Vídeo até cinco minutos	link fornecido; conferir acesso e duração
README e relatório	arquivos atualizados nesta entrega

17 | Fontes e materiais de reprodução

GitHub: https://github.com/lapera555-ux/FarmTech-VisionGuard-Grupo60acabado

Colab: https://colab.research.google.com/drive/1vvTeSznq2Ij-vpL9D-kuqE7l_I1J5fR1?usp=sharing

Vídeo: https://youtube.com/shorts/eRFRtGnIlJY

Referências: Open Images (storage.googleapis.com/openimages); YOLOv5 (github.com/ultralytics/yolov5); Make Sense (makesense.ai); PyTorch (pytorch.org); TensorFlow (tensorflow.org).

18 | Encaminhamento prático

Antes do envio, atualizar README.md no repositório com o documento revisado, acrescentar este PDF em reports/ e confirmar que os links públicos funcionam. Não declarar Make Sense completo sem rotulagem manual. Após o prazo, não realizar commits se a regra da FIAP proibir alterações posteriores.